Svojstva signala

Druga laboratorijska vježba iz Signala i sustava

Grupa autora

Sadržaj

1 Uvod **2**

2 Periodičnost signala **2**
2.1 Priprema 3
2.2 Periodičnost signala 5

3 Energija i snaga signala **6**
3.1 Energija signala 6
3.2 Snaga periodičnog signala 7

4 Norme signala i kutevi među njima **8**
4.1 Norma signala 8
4.2 Kutevi između signala 8

1 Uvod

Laboratorijske vježbe iz Signala i sustava će vas približiti problematici obrade signala te analize i simulacije sustava. Sve vježbe se izvode na računalu u programskom sustavu MATLAB[1]. Osim što posjeduje mogućnost izvođenja raznih matematičkih operacija, numeričkih i simboličkih, MATLAB[2] sadrži i modul Simulink[3] koji je vizualni alat za brzo i jednostavno simuliranje sustava. S MATLAB-om i Simulinkom ste se upoznali na uvodnoj laboratorijskoj vježbi.

FER-ova licenca vam omogućuje lokalnu instalaciju ovog programskog paketa, ali i *online* korištenje. Napomenimo da osim komercijalnog programskog paketa MATLAB postoji i javno dostupni GNU Octave[4] koji je gotovo kompatibilan (bez Simulinka), a vrlo je sličan i SciPy[5] paket za Python[6].

Dio rezultata vježbe potrebno je predati preko FER-ovog Moodle[7] sustava, a datoteku s rezultatima je potrebno postaviti na mrežni disk do zadanog roka. Dozvoljeno je konzultirati se s kolegama, ali uz samostalni rad. Ovisno o zadatku, unose se numerički rezultati, slike ili programski kod. Svrha laboratorijskih vježbi jest učenje, odnosno bolje razumijevanje koncepata signala i sustava, kao i njihova primjena. Stoga svaki zadatak možete ponoviti neograničen broj puta, dok ne zaključite da ste dobili točan rezultat. U tome vam mogu pomoći i naši asistenti ili demonstratori.

Za prolaz predmeta morate pristupiti svim laboratorijskim vježbama i u svakoj ostvariti barem polovicu točnih rezultata. Uopće ne sumnjamo da ćete baš Vi imati 100% točnih!

2 Periodičnost signala

Cilj druge laboratorijske vježbe je upoznavanje s upotrebom MATLAB-a kao alata za rješavanje zadataka iz područja reprezentacije i svojstava signala. Od vas se očekuje da ćete nakon ove vježbe moći na računalu prikazati različite oblike kontinuiranih i diskretnih signala, da ćete moći ispitati periodičnost te izračunati snagu i energiju signala.

[1] https://www.fer.unizg.hr/matlab
[2] https://www.mathworks.com/products.html?s_tid=gn_ps
[3] https://www.mathworks.com/products/simulink.html
[4] https://octave.org/
[5] https://scipy.org/
[6] https://www.python.org/
[7] https://moodle.fer.hr/

```
%% Audio recorder initialization
Fs = 44100; % Sampling rate 44.1 kHz
Nb = 16;    % Number of bits 16
Nc = 1;     % Number of channels 1 (mono)
ID = -1;    % Audio device identifier (default)
T  = 2;     % Recording duration 2 sec

info = audiodevinfo % Returns information about the input
                    % and output audio devices on the system
info.input(1) % Display the information about
              % the first input device
% optional
% ID = 0; % uncomment to select the input audio device
          % specified by the device identifier (ID) 0

% Create an audio recording object
recObj = audiorecorder(Fs, Nb, Nc, ID);
```

Listing 1: Inicijalizacija audio recordera

2.1 Priprema

Vaš prvi korak je snimiti govorne signale. Dvaput ćete izgovoriti i snimiti riječ "da", a dvaput riječ "ne". Nakon predobrade, snimljene signale ćete koristiti za nastavak vježbe.

Najprije morate inicijalizirati audio recorder (Listing 1). Ako želite odabrati određeni ulazni audio uređaj najprije koristite naredbu *audiodevinfo* koja vraća informacije o audio uređajima spojenim na sustav. Zatim provjerite koji ID je dodijeljen vašem željenom uređaju te u varijablu ID zapišite ID tog uređaja.

Naš sljedeći korak je snimanje zvuka. Pokrenite programski odsječak (Listing 2) i izgovorite traženu riječ. Naravno, prikazat ćete i preslušati snimljeno, kako biste se uvjerili da je sve u redu.

Ako je u redu, trajanje snimljenih signala trebalo bi biti vidljivo kraće od ukupnog trajanja snimanja ($< T = 2s$), a snimke bi trebale biti podjednake dužine. Magnituda snimljenih signala trebala bi biti veća od 0.2 a manja od 1, kada bi signal ušao u zasićenje. Ponovite postupak po potrebi.

Snimljene podatke potrebno je pridijeliti varijablama *da1*, *da2*, odnosno *ne1* i *ne2* (kao na primjer naredbom *da1 = x;* pa ekvivalentno i za ostale).

Sigurno ste primijetili da sve snimljene riječi **ne počinju** u istom trenutku. Stoga ćemo ih poravnati našom funkcijom *alignsig()*. U tu svrhu ova funkcija koristi vremensku kroskorelaciju dva signala, što u ovom trenutku još nismo učili. Dovoljno je znati da je ta operacija jako slična konvoluciji, a nju ćemo

```
%% Execute the following four lines (Ctrl+ENTER) and say a word:
disp('Start speaking.');
recordblocking(recObj, T)
disp('End of recording.');

x = getaudiodata(recObj); % Extract the audio data

%% Check the recording
% Plot the result
figure, plot(x), grid

% Listen to the recording
soundsc(x, Fs, Nb);

% Repeat the procedure until obtaining a satisfactory recording
```

Listing 2: Snimanje i provjera snimljenog zvuka

```
function sig = alignsig(ref, sig)
%ALIGNSIG
%   [SIG] = ALIGNSIG(REF, SIG)
%   Aligns SIG to REF, adjust SIG length to REF length

% Correlation == convolution with reversed sig
corrRefSig = conv(ref, sig(end:-1:1));
% Maximum corresponds to the best alignment
[~, ind] = max(abs(corrRefSig));
% Calculate delay of sig to the reference
delay = length(sig) - ind;

if delay > 0            % sig is delayed
    sig(1:delay) = []; % remove the delay
elseif delay < 0        % sig is advanced
    sig(1-delay:end-delay) = sig; % add the delay
    sig(1:-delay) = 0;
end

% adjust the length of sig
len = length(ref);
sig(len+1) = 0;        % extend
sig(len+1:end) = [];  % cut the surplus
```

Listing 3: Funkcija za poravnavanje signala

```
%% Align signals
da1 = alignsig(da2, da1);
ne1 = alignsig(da2, ne1);
ne2 = alignsig(da2, ne2);
```

Listing 4: Primjer poravnavanja signala, ako je *da2* referentan

```
%% Save signals
save('audioSignals.mat', 'da1', 'da2', 'ne1', 'ne2');

% to load audioSignals use command load
% load('audioSignals.mat')
```

Listing 5: Primjer spremanja signala

detaljno izučavati nešto kasnije. Programski kôd funkcije ćete naći u Listing 3. Funkciju je potrebno pohraniti u datoteku naziva *alignsig.m* u vašu radnu mapu (*Current Folder*).

Kako ćete poravnati signale? Odaberite jedan za referentni, na primjer onaj kojem je snimljena riječ najbolje centrirana u sredini intervala. Neka je u našem primjeru to *da2*. Ostale ćemo poravnati prema njemu: vidi Listing 4.

Sačuvajte poravnate signale *da1*, *da2*, *ne1*, *ne2* za buduće vježbe! Vidi Listing 5.

2.2 Periodičnost signala

Najprije razmatramo signale $x_1(t) = \sin\left(\frac{4\pi}{T}t\right)$ i $x_2(t) = \sin\left(\frac{2\pi}{T}t^2\right)$ pri čemu je konstanta T i dalje $T = 2$.

a) Nacrtajte zadana dva signala na intervalu $t \in [0, 2T]$ korištenjem naredbi *figure, plot(...)*. Kako ćete zadati vektor t? Neka korak vremena bude $T/1000$. Hoćete li u izrazu za t^2 koristiti t^2 ili t.^2. Zašto? Možete li temeljem dobivenih slika zaključiti da li je pojedini signal periodičan ili nije?

b) Definirajte periodičnost vremenski kontinuiranog signala.

c) Po definiciji, ispitajte koji su od zadanih signala periodični. Za periodične signale odredite njihov osnovni period.

d) Snimljeni signal *ne1* sadrži periodičnu komponentu na mjestu samoglasnika "e". Nacrtajte signal u MATLAB-u, pronađite to mjesto (Tools/Zoom In, Tools/Data Tips + arrow keys za "šetnju" po krivulji, ...), izrežite jednu periodu i pridijelite varijabli *y1*. U tu svrhu, koristite operator dvotočka (kao npr. *y1 = ne1(28507:28871);*). Prikažite dobiveni signal pomoću naredbi *figure, stem(...)*

Koliko uzoraka *N* je u jednoj periodi? Koliko je to sekundi, ako znamo da je Fs = 44100 Hz? Kolika je bila frekvencija vaših glasnica dok ste izgovarali "e"?

Generirajte umjetni periodični signal tako da sto puta ponovite snimljenu izrezanu periodu (naredba *z1 = repmat(y1, 100, 1);*). Poslušajte takav signal (naredba *soundsc(z1, Fs, Nb);*)!

e) Ponovite isto za "da1", odnosno samoglasnik "a". Sada neka varijable budu *y2, z2*. Kolika je bila frekvencija vaših glasnica dok ste izgovarali "a"?

3 Energija i snaga signala

Prethodni dio laboratorijske vježbe se bavio ispitivanjem periodičnosti kontinuiranih i diskretnih signala.

U ovom dijelu računat ćemo njihovu energiju i snagu.

3.1 Energija signala

Totalnu energiju diskretnog signala računamo kao:

$$E_T = \sum_n |x[n]|^2.$$

Kolika je totalna energija snimljenih **diskretnih** signala *da1*, *da2*, odnosno *ne1* i *ne2*? U varijable *Eda1*, *Eda2*, *Ene1* i *Ene2* spremite vrijednosti totalne energije snimljinih signala.

Za numerički izračun ovakvih izraza, netko bi mogao koristiti *for* petlju koja ide po svim uzorcima, kvadrira apsolutnu vrijednost i pribraja, što daje prilično sporu i nepreglednu realizaciju. Isti rezultat daje i puno elegantnija naredba *sum*(*abs*(*x*).^2). Međutim, najelegantnija implementacija je skalarni produkt dvaju vektora:

$$Et = x' * x;$$

Redak-vektor množimo sa stupac-vektorom. **Zapamtimo taj trik** za buduće zadatke!

Totalnu energiju kontinuiranog signala računamo kao:

$$E_T = \int_t |x(t)|^2 dt.$$

Kolika je totalna energija signala $x_1(t) = \sin\left(\frac{4\pi}{T}t\right)$ na intervalu $t \in [0, 2T]$ uz $T = 2$? Izračunajte analitički olovkom na papiru.

Isti problem izračunajte analitički korištenjem paketa za simboličku matematiku. Evo podsjetnika:

$$syms\ t$$

$$int(abs(sin(4 * sym(pi)/2 * t))^2, t, 0, 2 * T)$$

Naši snimljeni signali *da1*, *da2*, odnosno *ne1* i *ne2* su ustvari **očitanja kontinuiranih funkcija**. Ako za izračun gornjeg integrala koristimo Eulerovu aproksimaciju, numerički izračunajte totalnu energiju pripadajućih kontinuiranih signala:

$$E_T = \int_t |x(t)|^2 dt \approx T_s \sum_n |x(T_s n)|^2 = 1/F_s \sum_n |x[n]|^2.$$

3.2 Snaga periodičnog signala

Totalnu srednju snagu periodičnog diskretnog signala računamo kao:

$$P_T = 1/N \sum_{<N>} |x[n]|^2,$$

gdje je N perioda.

Kolika je totalna srednja snaga periodičnih **diskretnih** signala *z1* i *z2*? Izračunajte numerički i vrijednosti spremite u varijable *Pz1* i *Pz2*. Prisjetimo se, to su periodički prošireni glasovi "e" i "a" koje smo snimili i pripremili u prethodnom poglavlju.

Ako smatramo da su *z1* i *z2* ustvari **očitanja kontinuiranih funkcija** te ako koristimo Eulerovu aproksimaciju integrala, numerički izračunajte totalnu srednju snagu pripadajućih kontinuiranih signala i vrijednosti spremite u varijable *Pz1k* i *Pz2k*.

4 Norme signala i kutevi među njima

U ovom dijelu računat ćemo norme signala, te kuteve između njih.

4.1 Norma signala

ℓ_2 norma diskretnog signala je:

$$||x[n]||_2 = \sqrt{\sum_n |x[n]|^2}.$$

Uočimo da je to kvadratni korijen iz totalne energije, koju smo već izračunali za naše diskretne signale *da1*, *da2*, *ne1* i *ne2*. To ćemo iskoristiti u narednom odlomku.
ℓ_1 norma diskretnog signala je:

$$||x[n]||_1 = \sum_n |x[n]|.$$

Izračunajte ℓ_1 norme naših diskretnih signala *da1*, *da2*, *ne1* i *ne2* i vrijednosti spremite u varijable *L1da1*, *L1da2*, *L1ne1* i *L1ne2*.

4.2 Kutevi između signala

Kut između signala f i g iz prostora signala ℓ_2 ili L_2 definiramo kao

$$\cos\varphi = \frac{\langle f, g\rangle}{||f||_2||g||_2}.$$

Skalarni produkt $\langle f, g\rangle$ za diskretne signale iz ℓ_2 definiran je kao:

$$\langle f[n], g[n]\rangle = \sum_n f[n]g^*[n].$$

Za inverznu kosinus funkciju koristiti naredbu *acos(...)*. Ne zaboravite na trik kako računati skalarni produkt vektora i izračunajte kuteve između naših snimljenih signala.

Da li je potrebno računati sve kombinacije? Koliko ima različitih?

Ortogonalni signali su pod kutem od $\pi/2$. Izračunajte apsolutnu vrijednost odstupanja od $\pi/2$ i rezultate u radijanima upišite u matricu. Matricu nazovite *tablica1*. Matrica mora imati četiri retka i četiri stupca, a elementi matrice

odgovaraju apsolutnom odstupanju kuta od $\frac{\pi}{2}$. Izgled matrice možete vidjeti u nastavku. Sa $\angle(s1, s2)$ smo označili kut između signala *s1* i *s2*. Komentirajte rezultate.

tablica1 =

$$\begin{bmatrix} |\frac{\pi}{2} - \angle(da1, da1)| & |\frac{\pi}{2} - \angle(da1, da2)| & |\frac{\pi}{2} - \angle(da1, ne1)| & |\frac{\pi}{2} - \angle(da1, ne2)| \\ |\frac{\pi}{2} - \angle(da2, da1)| & |\frac{\pi}{2} - \angle(da2, da2)| & |\frac{\pi}{2} - \angle(da2, ne1)| & |\frac{\pi}{2} - \angle(da2, ne2)| \\ |\frac{\pi}{2} - \angle(ne1, da1)| & |\frac{\pi}{2} - \angle(ne1, da2)| & |\frac{\pi}{2} - \angle(ne1, ne1)| & |\frac{\pi}{2} - \angle(ne1, ne2)| \\ |\frac{\pi}{2} - \angle(ne2, da1)| & |\frac{\pi}{2} - \angle(ne2, da2)| & |\frac{\pi}{2} - \angle(ne2, ne1)| & |\frac{\pi}{2} - \angle(ne2, ne2)| \end{bmatrix}$$

Sve varijable iz radnog prostora (workspace) po završetku vježbe pohranite u datoteku "JMBAG.mat":

$$save\ 0123456789.mat$$

gdje 0123456789 treba zamijeniti vašim matičnim brojem.

Ne zaboravite predati vaše rezultate koje ste dobili u MATLAB/Octave-u na mrežni disk! Datoteku morate postaviti u zadani mrežni direktorij, kako je navedeno u: https://www.fer.unizg.hr/predmet/sis/obavijesti.

U predanom radnom prostoru moraju se nalaziti varijable:

- da1, da2, ne1 i ne2 sa snimkama Vaših glasova,
- y1, z1, y2 i z2 gdje se nalaze Vaši "izrezani" glasovi te umjetni periodički signal generiran pomoću njih,
- Eda1, Eda2, Ene1 i Ene2 u koje ste spremili vrijednosti totalne energije diskretnih signala vaših glasova,
- Pz1 i Pz2 u kojima su spremljene vrijednosti totalne srednje snage diskretnih signala z1 i z2,
- Pz1k i Pz2k s vrijednostima koje odgovaraju totalnoj srednjoj snazi z1 i z2 uz pretpostavku da su dobiveni signali očitanja kontinuirane funkcije (Eulerova aproksimacija),

- L1da1, L1da2, L1ne1 i L1ne2 u koje ste spremili vrijednosti l_1 norme Vaših glasova,
- tablica1 (matrica dimenzija 4×4) u koju ste spremili apsolutnu vrijednost odstupanja kuta između promatranih signala i konstante $\frac{\pi}{2}$.