Fourierove transformacije

Treća laboratorijska vježba iz Signala i sustava

Grupa autora

Sadržaj

1 Uvod **2**

2 Frekvencijska analiza vremenski kontinuiranih signala **2**
2.1 Vremenski kontinuirana Fourierova transformacija (CTFT) . . 4
2.2 Vremenski kontinuiran Fourierov red (CTFS) 5

3 Frekvencijska analiza vremenski diskretnih signala **6**
3.1 Vremenski diskretna Fourierova transformacija (DTFT) 7
3.2 Vremenski diskretan Fourierov red (DTFS) 8

1 Uvod

Laboratorijske vježbe iz Signala i sustava će vas približiti problematici obrade signala te analize i simulacije sustava. Sve vježbe se izvode na računalu u programskom sustavu MATLAB[1]. Osim što posjeduje mogućnost izvođenja raznih matematičkih operacija, numeričkih i simboličkih, MATLAB[2] sadrži i modul Simulink[3] koji je vizualni alat za brzo i jednostavno simuliranje sustava. S MATLAB-om i Simulinkom ste se upoznali na uvodnoj laboratorijskoj vježbi.

Napomenimo da osim komercijalnog programskog paketa MATLAB postoji i javno dostupni GNU Octave[4] koji je gotovo kompatibilan (bez Simulinka), a vrlo je sličan i SciPy[5] paket za Python[6].

Izvještaj s vježbe potrebno je predati preko FER-ovog Moodle[7] sustava do zadanog roka. Dozvoljeno je konzultirati se s kolegama, ali uz samostalni rad. Svaki student dobiva jedinstvene zadatke i upute putem Moodlea. Ovisno o zadatku, unose se numerički rezultati, slike ili programski kod. Svrha laboratorijskih vježbi jest učenje, odnosno bolje razumijevanje koncepata signala i sustava, kao i njihova primjena. Stoga svaki zadatak možete ponoviti neograničen broj puta, dok ne zaključite da ste dobili točan rezultat. U tome vam mogu pomoći i naši asistenti ili demonstratori.

Za prolaz predmeta morate pristupiti svim laboratorijskim vježbama i u svakoj ostvariti barem polovicu točnih rezultata. Uopće ne sumnjamo da ćete baš Vi imati 100% točnih!

2 Frekvencijska analiza vremenski kontinuiranih signala

Prvi dio laboratorijske vježbe bavi se Fourierovom transformacijom vremenski kontinuiranih signala. Razlikujemo vremenski kontinuiranu Fourierovu transformaciju i vremenski kontinuiran Fourierov red.

Vremenski kontinuirana Fourierova transformacija (CTFT, engl. *Continuous Time Fourier Transform*) koristi se za analizu **aperiodičkih** vremenski kontinuiranih signala. Pomoću CTFT kontinuirani aperiodičan signal opisujemo s neprebrojivo mnogo kompleksnih eksponencijalnih funkcija.

[1] https://www.fer.unizg.hr/matlab
[2] https://www.mathworks.com/products.html?s_tid=gn_ps
[3] https://www.mathworks.com/products/simulink.html
[4] https://octave.org/
[5] https://scipy.org/
[6] https://www.python.org/
[7] https://moodle.fer.hr/

Vremenski kontinuirani Fourierov red (CTFS, engl. *Continuous Time Fourier Series*) koristi se za analizu **periodičkih** vremenski kontinuiranih signala. Pomoću Fourierovoga reda kontinuirani periodičan signal konačne snage opisujemo diskretnim skupom spektralnih komponenata koje zovemo harmonici.

```
%% Define symbolic variables
syms t w real
% Define parameter a
a = 0.5;

%% Define signal x
x = heaviside(t+a)-heaviside(t-a);
% Plot x
figure, ezplot(x,[-a-1,a+1]), grid on, title('Signal x')

%% Calculate CTFT
X=fourier(x,w);
pretty(simplify(X)) % simplify and display X

%% Plotting magnitude and phase response...
% ezplot(symbolic_function, range)

% Amplitude/Magnitude
figure, ezplot(abs(X),[-20,20]), grid on,
title('Amplitudni spektar')

%% Phase
figure, ezplot(atan(imag(X)/real(X)),[-20,20]), grid on,
title('Fazni spektar')

%% Calculate ICTFT
xr = ifourier(X,t);

% Plot xr
figure, ezplot(xr,[-a-1,a+1]), grid on,
title('Signal x dobiven primjenom ICTFT-a')
```

Listing 1: Izračun CTFT-a i ICTFT-a

2.1 Vremenski kontinuirana Fourierova transformacija (CTFT)

Fourierova transformacija kontinuiranog signala (CTFT) x glasi

$$X(j\omega) = \int_{-\infty}^{\infty} x(t)e^{-j\omega t}dt, \quad \omega \in \mathbb{R},$$

dok je pripadna inverzna transformacija (ICTFT)

$$x(t) = \frac{1}{2\pi}\int_{-\infty}^{\infty} X(j\omega)e^{j\omega t}d\omega, \quad t \in \mathbb{R}.$$

Izračun CTFT-a i ICTFT-a se može uraditi pomoću MATLAB-a ili Octavea korištenjem simboličkog paketa. Naredbe za CTFT i ICTFT su redom `fourier` te `ifourier`. Listing 1[8] prikazuje primjer kako izračunati Fourierovu transformaciju za centrirani pravokutni puls $x(t) = \mu(t+\frac{1}{2})-\mu(t-\frac{1}{2})$ jedinične površine. Ako niste instalirali *Symbolic Math Toolbox* prilikom instalacije MATLAB-a, možete ga instalirati unutar MATLAB-a (Home/Add-Ons i u tražilicu upišete *Symbolic Math Toolbox*). Ako koristite Octave, upute za instalaciju možete pronaći na `https://github.com/cbm755/octsympy/wiki` i `https://gnu-octave.github.io/packages/symbolic/`. Ne zaboravite da na računalu morate imati instaliranu i odgovarajuću verziju Pythona (provjerite s kojom verzijom Pythona je Octave povezan!).

a) Promatramo kontinuirani signal

$$x(t) = \begin{cases} 1, & |t| < \frac{a}{2} \\ 0, & \text{inače} \end{cases}, \qquad a > 0.$$

Analitički odredite Fourierovu transformaciju kontinuiranog signala x i usporedite ga s rješenjem koje dobijete pomoću MATLAB-a. Nacrtajte amplitudni i fazni spektar signala x za različite vrijednosti parametra a. Što se događa sa spektrom signala kada povećamo parametar a? Što dobivamo u slučaju kada $a \to +\infty$? Izračunajte energiju signala x.

b) Promatramo kontinuirani signal

$$x(t) = \begin{cases} \cos(\omega_0 t), & |t| < \frac{a}{2} \\ 0, & \text{inače} \end{cases}, \qquad \omega_0 = 4\pi, \ \ a > 0.$$

Analitički odredite Fourierovu transformaciju kontinuiranog signala x i usporedite ga s rješenjem koje dobijete pomoću MATLAB-a. Nacrtajte amplitudni i fazni spektar signala x za različite vrijednosti parametra a. Što se događa sa spektrom signala kada povećamo parametar a? Što dobivamo u slučaju kada $a \to +\infty$?

[8] Ako koristite MATLAB, za crtanje možete koristiti noviju naredbu fplot umjesto ezplot.

2.2 Vremenski kontinuiran Fourierov red (CTFS)

Fourierov red kontinuiranog periodičkog signala x osnovne periode T_0 glasi

$$X_k = \frac{1}{T_0} \int_{T_0} x(t) e^{-jk\frac{2\pi}{T_0}t} dt, \quad k \in \mathbb{Z}, \tag{1}$$

dok je pripadna inverzna transformacija (ICTFS)

$$x(t) = \sum_{k \in \mathbb{Z}} X_k e^{jk\frac{2\pi}{T_0}t}, \quad t \in \mathbb{R}.$$

Izračun koeficijenata Fourierovog reda, točnije izračun integrala, moguće je napraviti korištenjem simboličkog paketa u MATLAB-u ili Octaveu. Primjer za izračun, evaluaciju vrijednosti i grafički prikaz spektra možete pronaći u Listing 2.

```
%% Define symbolic variables
syms t k real

% Define signal x and calculate period
omega0 = 2*pi;
x = sin(omega0*t);
T0 = 2*pi/omega0;

%% Calculate CTFS by definition
X = int(x*exp(-2*pi*1j/T0*t*k),-T0/2,T0/2)/T0;
pretty(simplify(X)) % Display solution

%% Evaluate symbolic function at n=-5,-4,...,4,5.
n = -7:1:7;
X_values = zeros(length(n),1); % Allocate memory
for nn = n
    X_values(nn-min(n)+1)=subs(limit(X,k,nn));
end

%% Plotting Magnitude and Phase
figure, stem(n,abs(X_values)), grid on,
title('Amplitudni spektar')
figure, stem(n,angle(X_values)), grid on,
title('Fazni spektar')
```

Listing 2: Izračun, evaluacija vrijednosti i grafički prikaz za CTFS

a) Promatramo kontinuirani periodički signal

$$x(t) = 10\sin(60\pi t) + 5\cos(10\pi t).$$

Odredite osnovnu periodu T_0 signala x. Analitički izračunajte koeficijente Fourierovoga reda i usporedite ih s rješenjem koje dobijete pomoću MATLAB-a. Grafički prikažite amplitudni i fazni spektar. Koliko koeficijenata Fourierovoga reda je različito od nule? Izračunajte snagu signala x.

b) Promatramo umjetne periodičke signale z1 i z2 iz Druge laboratorijske vježbe. Podsjećamo da su z1 i z2 dobiveni ponavljanjem signala y1 i y2. Signali y1 i y2, a time i z1 i z2, dobiveni su iz očitanja kontinuiranih signala. Potrebno je procijeniti koeficijente Fourierovoga reda iz jednadžbe 1 korištenjem Eulerove aproksimacije

$$X_k \approx \frac{1}{N}\sum_{\langle N\rangle} x[n]e^{-jk\frac{2\pi}{N}n},$$

pri čemu je N period signala x, a pomoću $\langle N\rangle$ smo naznačili da suma ide po jednom periodu.

U varijablu naziva `z1ctfs` koja je vektor stupac (dimenzije su 201×1, a tip podatka je *double*) spremite koeficijente Fourierovog reda signala z1 korištenjem Eulerove aproksimacije za indekse $k = -100, -99, ..., 99, 100$. Nacrtajte amplitudni i fazni spektar. Koliko iznosi osnovna frekvencija signala z_1 ako je $F_s = 44100\,Hz$? Vrijednost te frekvencije spremite u varijablu `z1frek`.

U varijablu `z2ctfs` koja je vektor stupac (dimenzije su 201×1, a tip podatka je *double*)) spremite koeficijente Fourierovoga reda signala z2 korištenjem Eulerove aproksimacije za indekse $k = -100, -99, ..., 99, 100$. Nacrtajte amplitudni i fazni spektar. Koliko iznosi je osnovna frekvencija signala z_2 ako je $F_s = 44100\,Hz$? Vrijednost te frekvencije spremite u varijablu `z2frek`.

3 Frekvencijska analiza vremenski diskretnih signala

Drugi dio laboratorijske vježbe bavi se Fourierovom transformacijom vremenski diskretnih signala. Razlikujemo dvije Fourierove transformacije, vremenski diskretnu Fourierovu transformaciju i vremenski diskretan Fourierov red.

Vremenski diskretna Fourierova transformacija (DTFT, engl. *Discrete Time Fourier Transform*) koristi se za analizu **aperiodičkih** vremenski diskretnih signala. Pomoću Fourierovog integrala aperiodičan signal konačne energije opisujemo s neprebrojivo mnogo eksponencijalnih funkcija. Spektar je periodička funkcija frekvencije.

Vremenski diskretan Fourierov red (DTFS, engl. *Discrete Time Fourier Series*) koristi se za analizu **periodičkih** vremenski diskretnih signala. Pomoću Fourierovog reda periodičan signal konačne snage opisujemo prebrojivim skupom spektralnih koeficijenta koje zovemo harmonici. Vremenski diskretan Fourierov red je usko povezan s diskretnom Fourierovom transformacijom (DFT, engl. *Discrete Fourier Transform*). Obje transformacije, DTFS i DFT, su gotovo jednake i razlikuju se samo u neznatno drugačijem odabiru normalizacijskih koeficijenata. Kada računamo DFT ili DFTS na računalu koristimo algoritam **brze Fourierove transformacije** (FFT, engl. *Fast Fourier Transform*) kojim se efikasno računa DFT uz korištenje principa podijeli-pa-vladaj.

3.1 Vremenski diskretna Fourierova transformacija (DTFT)

Fourierova transformacija diskretnog signala x glasi

$$X(e^{j\Omega}) = \sum_{n\in\mathbb{Z}} x[n]e^{-j\Omega n}, \quad \Omega \in \mathbb{R},$$

dok je pripadna inverzna transformacija (IDTFT)

$$x[n] = \frac{1}{2\pi}\int_{-\pi}^{\pi} X(e^{j\Omega})e^{j\Omega n}d\Omega, \quad n \in \mathbb{Z}.$$

Uočite da je spektar $X(e^{j\Omega})$ periodičan i da mu je perioda 2π.

Izračun DTFT-a se može napraviti pomoću MATLAB-a ili Octavea naredbom `freqz`. Listing 3 daje primjer kako izračunati Fouerierovu transformaciju za diskretan signal konačnog trajanja $x[n] = \{...0, 0, \underline{1}, 1, 1, 0, 0, ...\}$. Ako niste instalirali *Signal Processing Toolbox* prilikom instalacije MATLAB-a, možete ga instalirati unutar MATLAB-a (Home/Add-Ons i u tražilicu upišete *Signal Processing Toolbox*).

a) Promatramo diskretni signal konačnog trajanja

$$x[n] = \{...0, 0, \underline{1}, -2, 1, -2, 1, 0, 0, ...\}.$$

Analitički odredite Fourierovu transformaciju diskretnog signala x i usporedite ga s rješenjem koje dobijete pomoću MATLAB-a. Nacrtajte amplitudni i fazni spektar signala x. Izračunajte energiju signala x.

```
% Signal x = {...,0,0,_1_,1,1,0,0,...}
x = [1 1 1];

% Define vector omega
w = linspace(-pi,pi,5000);

% Determine DTFT
X = freqz(x,1,w);

% Plotting Magnitude and Phase
figure, plot(w,abs(X)), grid on,
title('Amplitudni spektar')

figure, plot(w,angle(X)), grid on,
title('Fazni spektar')
```

Listing 3: Izračun i grafički prikaz za DTFT

b) Promatramo signal `ne1` iz druge laboratorijske vježbe. Odredite njegovu Fourierovu transformaciju na intervalu $\Omega \in [-\pi, \pi]$ u 5000 ekvidistantnih točaka (vidi Listing 3). Pospremite rezultat u varijablu `ne1dtft`. Nacrtajte amplitudni spektar. Promijenite frekvencijsku os tako da odgovara stvarnim frekvencijama: $\omega \in \left[-\frac{F_s}{2}, \frac{F_s}{2}\right]$. Možete li iz slike odrediti osnovnu frekvenciju vašeg glasa? Usporedite tu frekvenciju s osnovnom frekvencijom `z1frek` iz zadatka 2.2.b. Jesu li vrijednosti frekvencija približno jednake? Možete li pronaći više harmonike glasa `ne1` u amplitudnom spektru?

c) Ponovite prethodni zadatak za glas `da1` iz druge laboratorijske vježbe. Rezultat pospremite u varijablu `da1dtft`. Ovoga puta usporedbu radite s osnovnom frekvencijom `z2frek`.

3.2 Vremenski diskretan Fourierov red (DTFS)

Fourierov red diskretnog periodičkog signala x periode N glasi

$$X_k = \frac{1}{N}\sum_{n=0}^{N-1} x[n]e^{-j\frac{2\pi}{N}kn}, \quad k \in \mathbb{Z},$$

dok je pripadna inverzna transformacija (IDTFS)

$$x[n] = \sum_{k=0}^{N-1} X_k e^{j\frac{2\pi}{N}kn}, \quad n \in \mathbb{Z}.$$

Uočite da je i spektar X_k periodičan i da mu je perioda također N.
Za signal x duljine N promatramo diskretnu Fourierovu transformaciju (DFT)

$$X[k] = \sum_{n=0}^{N-1} x[n]e^{-j\frac{2\pi}{N}kn}, \quad k = 0, 1, 2, \ldots, N-1,$$

i pripadnu inverznu transformaciju (IDFT)

$$x[n] = \frac{1}{N}\sum_{k=0}^{N-1} X[k]e^{j\frac{2\pi}{N}kn}, \quad n = 0, 1, 2, \ldots, N-1.$$

Više detalja o DFT-u možete pročitati u materijalima predmeta. Uočite da je jedina razlika između DTFS/IDTFS i DFT/IDFT para transformacija pozicija konstante $\frac{1}{N}$. Iskoristit ćemo diskretnu Fourierovu transformaciju, točnije brzu Fourierovu transformaciju, za izračun vremenski diskretnog Fourierovog reda. Listing 4 prikazuje primjer izračuna Fourierovog reda za diskretan periodičan signal

$$x[n] = \{\ldots, 0, -1, 1, 2, 0, 1, \underbrace{-1, 1, 2, 0, 1}_{\text{perioda}}, -1, 1, 2, 0, 1, -1, \ldots\}$$

periode $N = 5$. Rezultat naredbe `fft` su koeficijenti spektra od indeksa 0 do $N-1$. Ponekad je prikladnije promatrati koeficijente spektra simetrično oko nule (prisjetite se da je spektar periodičan). To možemo napraviti naredbom `fftshift`.

```
% One period of the signal x starting with n=0
x = [-1;1;2;0;1];

% Period length
N = length(x); % N = 5

% DTFS of x is the FFT divided by the length.
X = fft(x)/N;

% Amplitude from 0 to N-1 (4)
figure, stem(0:(N-1),abs(X)), grid on

% Amplitude from -(N-1)/2 to (N-1)/2 [from -2 to 2]
figure, stem(-2:2,abs(fftshift(X))), grid on
```

Listing 4: Izračun DTFS korištenjem FFT-a

a) Promatramo diskretan periodičan signal

$$x[n] = 1 + 2\cos(\pi n) + \cos(\frac{\pi}{2}n) + \sin(\frac{\pi}{2}n).$$

Odredite periodu signala x. Analitički odredite Fourierov red diskretnog periodičnog signala x i usporedite ga s rješenjem koje dobijete pomoću MATLAB-a ili Octavea. Nacrtajte amplitudni i fazni spektar signala x. Izračunajte snagu signala x.

b) Promatramo `y1` iz druge laboratorijske vježbe. Za potrebe ovog podzadatka smatramo da je `y1` jedna perioda nekog periodičkog signala. Odredite koeficijente Fourierovoga reda tog signala. Usporedite dobiveni spektar sa spektrom iz 2.2.b).

U varijablu `y1dtfs`, koja je vektor stupac, spremite rezultat. Neka koeficijenti Fourierovoga reda počinju indeksom 0 (**ne** koristiti `fftshift`).

c) Ponovite prethodni podzadatak za signal `y2` iz druge laboratorijske vježbe. Rezultat pospremite u `y2dtfs`.

Pobrišite viškove naredbom `clearvars -except da1 ne1 y1 z1 y2 z2 z1ctfs z2ctfs z1frek z2frek ne1dtft da1dtft y1dtfs y2dtfs`. Sve preostale varijable iz radnog prostora pohranite u datoteku "JMBAG.mat":

save 0123456789.*mat*

gdje 0123456789 treba zamijeniti vašim matičnim brojem.

Ne zaboravite predati vaše rezultate koje ste dobili u MATLAB/Octave-u u sustav Moodle, posljednji zadatak!

U predanom radnom prostoru moraju se nalaziti varijable:

- da1, ne1 sa snimkama Vaših glasova iz druge laboratorijske vježbe ,
- y1, z1, y2 i z2 gdje se nalaze Vaši "izrezani" glasovi te umjetni periodički signal generiran pomoću njih iz druge laboratorijske vježbe,
- z1ctfs i z2ctfs u kojem se nalaze koeficijenti Fouerierovoga reda za signale z1 i z2,
- z1frek i z2frek u kojem se nalaze osnovne frekvencije signala z1 i z2,
- ne1dtft i da1dtft s vrijednostima Fourierove transformacije signala ne1 i da1,
- y1dtfs i y2dtfs u kojim se nalaze koeficijenti Fourierovog reda signala čiji je jedan period y1 i y2.