Analiza sustava

Peta laboratorijska vježba iz Signala i sustava

Grupa autora

Sadržaj

1 Uvod **2**

2 Vremenski diskretni sustavi **2**

2.1 Dvotonska multifrekvencijska signalizacija 2

2.2 Računanje odziva vremenski diskretnih sustava 4

2.3 Metoda za detekciju znamenaka 7

1 Uvod

Svrha pete laboratorijske vježbe je približiti problematiku analize i simulacije sustava upotrebom MATLAB-a i Simulinka. Od vas se očekuje da ćete nakon ove vježbe moći uz pomoć MATLAB-a i Simulinka izraditi simulacijske modele sustava te analizirati njihova svojstva.

Rezultate vježbe potrebno je predati preko FER-ovog Moodle[1] sustava. Dozvoljeno je konzultirati se s kolegama, ali uz samostalni rad. Zadaci su personalizirani. Svrha laboratorijskih vježbi jest učenje, odnosno bolje razumijevanje koncepata signala i sustava, kao i njihova primjena. Stoga svaki zadatak možete ponoviti neograničen broj puta, dok ne zaključite da ste dobili točan rezultat. U tome vam mogu pomoći i naši asistenti u za to predviđenim terminima na koje se prijavljujete preko sustava za razmjenu grupa.

Napominjemo kako za prolaz predmeta morate pristupiti svim laboratorijskim vježbama i u svakoj ostvariti barem polovicu točnih rezultata.

2 Vremenski diskretni sustavi

Prvi dio pete laboratorijske vježbe bavi se vremenski diskretnim sustavima koje opisujemo pomoću diferencijskih jednadžbi sa stalnim koeficijentima. Kroz ovaj dio vježbe naučit ćemo kako se MATLAB i Simulink koriste za rješavanje jednadžbi diferencija.

Vremenski diskretan, linearan, vremenski stalan i kauzalan sustav možemo opisati linearnom jednadžbom diferencija sa stalnim koeficijentima

$$a_0 y[n] + a_1 y[n-1] + \cdots + a_N[n-N] = b_0 u[n] + b_1 u[n-1] + \cdots + b_M u[n-M].$$

Ako su svi koeficijenti a_i osim jednog (tipično a_0) jednaki nuli, govorimo o sustavu s impulsnim odzivom konačnog trajanja ili FIR sustavu (od eng. *finite impulse response*).

Ako su barem dva koeficijenta a_i različita od nule govorimo o sustavu s impulsnim odzivom beskonačnog trajanja ili IIR (od eng. *infinite impulse response*) sustavu.

Kako riješiti linearnu diferencijsku jednadžbu pomoću MATLAB-a i Simulinka pokazat ćemo na primjeru prepoznavanja znamenki kodiranih dvotonskom multifrekvencijskom signalizacijom.

2.1 Dvotonska multifrekvencijska signalizacija

Dvotonska multifrekvencijska signalizacija[2] (eng. *dual-tone multi-frequency*

[1] https://moodle.fer.hr/

[2] https://en.wikipedia.org/wiki/Dual-tone_multi-frequency_signaling

	2500Hz	3000Hz	3500Hz
500Hz	1	2	3
1000Hz	4	5	6
1500Hz	7	8	9
2000Hz	*	0	#

Figure 1: Znamenke i pripadajuće frekvencije.

signaling) je tehnika u telekomunikacijskim sustavima koja koristi glasovni frekvencijski pojas u telefonskoj liniji za komunikaciju između raznih komunikacijskih uređaja. Multifrekvencijska signalizacija je metoda koja koristi mješavinu više čistih tonova (čistih sinusnih valova). Dvotonska multifrekvencijska signalizacija koristi kombinaciju dva tona (dva sinusa) kako bi kodirala znamenke. U svrhu ove vježbe razvit ćemo vlastitu dvotonsku multifrekvencijsku signalizaciju za slanje znamenki i sustav za prepoznavanje tako kodiranih znamenki.

U komunikacijskim sustavima za prijenos glasa najčešće se koristi frekvencija uzorkovanja F_s = 8 kHz s obzirom da je korisna frekvencija glasa u rasponu od $0.3 - 3.4$ kHz. Sukladno tome, Nyquistova frekvencija je $F_{Nyquist} = F_s/2$ = 4 kHz. U telekomunikacijskim sustavima koristi se 7 frekvencija za kodiranje znamenki od "0" do "9" te znakova "*" i "#". Frekvencije se sastoje od skupa "donjih" frekvencija $\{$697 Hz, 770 Hz, 852 Hz, 941 Hz$\}$ i skupa "gornjih" frekvencija $\{$1209 Hz, 1336 Hz, 1477 Hz$\}$. Znamenka se kodira kao superpozicija jednog tona iz skupa "donjih" frekvencija i jednog tona iz skupa "gornjih" frekvencija.

Naš sustav će koristiti sljedećih 7 frekvencija: $\{$500 Hz, 1000 Hz, 1500 Hz, 2000 Hz, 2500 Hz, 3000 Hz, 3500 Hz$\}$. Znamenke će biti kodirane na isti način kao i u komunikacijskim sustavima, samo će sada skup "donjih" frekvencija biti $\{$500 Hz, 1000 Hz, 1500 Hz, 2000 Hz$\}$, a "gornjih" $\{$2500 Hz, 3000 Hz, 3500 Hz$\}$. Na slici 1 vidljivo je koja dva tona kodiraju pojedinu znamenku. Na primjer, znamenka "1" je signal koji se sastoji od dva tona (superpozicija dva sinusa), prvog od 500 Hz i drugog od 2500 Hz.

Signal koji kodira *i*-tu znamenku može se zapisati kao

$$u_i(t) = sin(2\pi f_{low} t) + sin(2\pi f_{high} t), \tag{1}$$

gdje je f_{low} jedna od frekvencija iz skupa "donjih" frekvencija, a f_{high} jedna od frekvencija iz skupa "gornjih" frekvencija. Npr., signal koji kodira znamenku "1" dan je kao

$$u_1(t) = sin(1000\pi t) + sin(5000\pi t). \tag{2}$$

Uočite kako su amplitude pojedinih komponenti signala $u_1(t)$ jednake 1, a maksimalna amplituda signala jednaka je 2.

Zadatak 1. Kako izgleda amplitudni spektar kontinuiranog signala $u_i(t)$? Izračunajte za signal $u_i(t)$ iz (1) CTFT i skicirajte amplitudni spektar.

Zadatak 2. Ako koristimo frekvenciju uzorkovanja F_s = 8 kHz, odredite izraz očitanog signala $u_i[n]$. Izračunajte za očitani signal $u_i[n]$ DTFT i skicirajte amplitudni spektar.

2.2 Računanje odziva vremenski diskretnih sustava

Želimo dizajnirati metodu koji detektira nalaze li se pojedine frekvencijske komponente u ulaznom signalu. Takva metoda bi se sastojala od 7 vremenski diskretnih sustava opisanih jednadžbama diferencija.

Pokazat ćemo na jednom primjeru analizu vremenski diskretnog sustava. Neka je zadan sustav drugog reda opisan diferencijskom jednadžbom

$$a_0y[n] + a_1y[n-1] + a_2[n-2] = b_0u[n] + b_1u[n-1] + b_2u[n-2]. \tag{3}$$

Dodatno, neka koeficijenti budu $a_0 = 1, a_1 = -0.98, a_2 = 0.91, b_0 = 1$ i $b_1 = b_2 = 0$. Naredbe za analizu sustava su: *tf* za definiciju sustava, *impulse* i *step* za određivanje impulsnog odziva i odziva na jediničnu stepenicu mirnog sustava te naredba *filter* za određivanje odziva sustava na proizvoljnu pobudu. Primjer korištenja naredbi pogledajte u Listingu 1.

Dok se naredba *filter* može koristiti i za računanje općeg odziva linearnog sustava, naredba *conv* služi isključivo za određivanje odziva mirnog sustava. U Listingu 2 pogledajte kako se naredba *conv* koristi za računaje odziva sustava za kojeg je $a_0 = 1$, $a_1 = a_2 = 0$, $b_0 = b_2 = 1$ i $b_1 = -2$, odnosno čiji je impulsni odziv $h[n] = \{\underline{1}, -2, 1\}$.

Već ste naučili kako konvolucija u vremenskoj domeni odgovara množenju u spektru. Spektar izlaznog signala $Y(e^{j\Omega})$ iz sustava odgovara umnošku $H(e^{j\Omega})U(e^{j\Omega})$, gdje su $Y(e^{j\Omega})$, $H(e^{j\Omega})$ i $U(e^{j\Omega})$ DTFT od izlaznog signala $y[n]$, impulsnog odziva $h[n]$ i ulaznog signala $u[n]$.

Pokažimo sada na primjeru primjenu diskretnog vremenskog filtra na diskretni dvotonski multifrekvencijski signal. Neka signal bude zadan kao

$$u[n] = sin\left(\frac{3\pi}{16}n\right) + sin\left(\frac{9\pi}{16}n\right). \tag{4}$$

```
%% Naredbe za analizu sustava
B = [1, 0, 0];  % definiramo koeficijente ulazne strane
A = [1, -0.98, 0.91];  % definiramo koeficijente izlazne strane
S = tf(B, A, 1)  % definiramo sustav opisan jednadžbom (3)
                 % treći argument je vrijeme uzorkovanja
                 % i moramo ga zadati jer se u protivnom
                 % podrazumijeva vremenski kont. sustav

figure; impulse(S);  % crtamo impulsni odziv sustava
figure; step(S);  % crtamo odziv na jedinični skok

n = 0:1:150;
u = cos(pi/12 * n);  % definiramo pobudu
y = filter(B, A, u);  % računamo odziv mirnog sustava na pobudu
figure; stem(n, y);  % crtamo odziv
```

Listing 1: Analiza vremenski diskretnog sustava pomoću MATLAB-a.

```
%% Conv command
h = [1, -2, 1];  % definiramo impulsni odziv sustava
n = 0:1:150;
u = cos(pi/12 * n);  % definiramo pobudu konačnog trajanja

y = conv(h, u);  % računamo odziv mirnog sustava na pobudu
figure; stem(y);  % crtamo odziv
```

Listing 2: Računanje odziva sustava pomoću naredbe *conv*.

Nadalje, neka vremenski diskretan sustav S_1 bude opisan diferencijskom jednadžbom

$$a_0 y[n] + a_1 y[n-1] + a_2[n-2] = b_0 u[n] + b_1 u[n-1] + b_2 u[n-2], \qquad (5)$$

gdje su $a_0 = 1$, $a_1 = 0.36$, $a_2 = 0.82$, $b_0 = 0.09$, $b_1 = 0$ i $b_2 = -0.09$, a vremenski diskretan sustav S_2 bude opisan istom diferencijskom jednadžbom pod (5) s koeficijentima $a_0 = 1$, $a_1 = -1.52$, $a_2 = 0.82$, $b_0 = 0.09$, $b_1 = 0$ i $b_2 = -0.09$. Amplitudno-frekvencijske karakteristike sustava $H_1(e^{j\Omega})$ i $H_2(e^{j\Omega})$ dane su na slici 2. Prikazana je desna polovica spektra na intervalu $[0, \pi]$, spektar je simetričan oko $\Omega = 0$.

Zadatak 3. Kako izgleda amplitudni spektar izlaznog signala $Y(e^{j\Omega})$ nakon što je ulazni signal iz (4) prošao kroz sustav S_1, a kako kroz sustav S_2? Koliko iznose amplitude ispred pojedinih frekvencijskih komponenti (ispred sinusa)

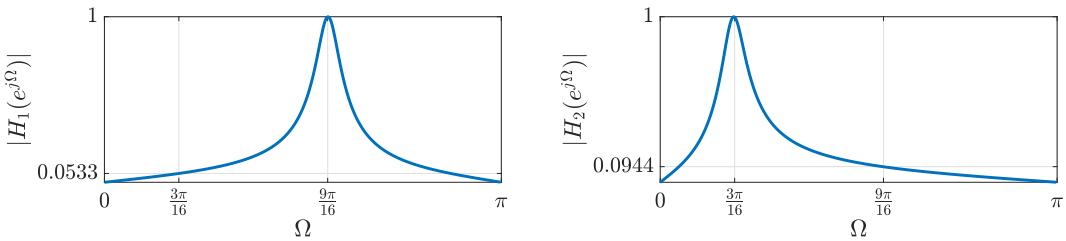

Figure 2: Amplitudno-frekvencijska karakteristika sustava S_1 i S_2.

```
%% DTMF signal
N = 150;
n = 0:1:N;
u = sin(3*pi/16*n) + sin(9*pi/16*n);  % definiramo pobudu
                                      % konačnog trajanja
%% Definiramo sustave
% sustav S1
B1 = [0.09, 0, -0.09];
A1 = [1, 0.36, 0.82];
% sustav S2
B2 = B1;
A2 = [1, -1.52, 0.82];

%% Računamo odzive
y1 = filter(B1, A1, u);  % odziv sustava S1 na pobudu
figure; plot(n, y1); title('y1')
y2 = filter(B2, A2, u);  % odziv sustava S2 na pobudu
figure; plot(n, y2); title('y2')
```

Listing 3: Generiranje signala $u[n]$ i računanje odziva sustava S_1 i S_2.

izlaza iz sustava S_1 i S_2 na pobudu $u[n]$ iz (4)?

Generirajmo u MATLAB-u signal $u[n]$ iz (4) i propustimo ga kroz sustave S_1 i S_2 koji su zadani jednadžbom (5). To možemo napraviti pomoću kodnog isječka u Listingu 3. Kolike su amplitude izlaznih signala ($y1$ i $y2$) i koje su dominantne frekvencije u svakom od njih?

Gledajući izlaze $y1$ i $y2$, možemo reći da sustav S_1 propušta ili "detektira" komponentu signala $u[n]$ na frekvenciji $\frac{9\pi}{16}$, a guši odnosno atenuira komponentu signala na frekvenciji $\frac{3\pi}{16}$. Isto tako možemo reći da sustav S_2 propušta ili "detektira" komponentu signala $u[n]$ na frekvenciji $\frac{3\pi}{16}$, a guši odnosno atenuira komponentu signala na frekvenciji $\frac{9\pi}{16}$.

		$i = 0$	$i = 1$	$i = 2$	$i = 3$	$i = 4$
500 Hz	a_i	1	-3.5548	5.0054	-3.2832	0.8533
	b_i	0.0029	0	-0.0058	0	0.0029
1000 Hz	a_i	1	-2.7207	3.6949	-2.5129	0.8533
	b_i	0.0029	0	-0.0058	0	0.0029
1500 Hz	a_i	1	-1.4724	2.3844	-1.3600	0.8533
	b_i	0.0029	0	-0.0058	0	0.0029
2000 Hz	a_i	1	0	1.8416	0	0.8533
	b_i	0.0029	0	-0.0058	0	0.0029
2500 Hz	a_i	1	1.4724	2.3844	1.3600	0.8533
	b_i	0.0029	0	-0.0058	0	0.0029
3000 Hz	a_i	1	2.7207	3.6949	2.5129	0.8533
	b_i	0.0029	0	-0.0058	0	0.0029
3500 Hz	a_i	1	3.5548	5.0054	3.2832	0.8533
	b_i	0.0029	0	-0.0058	0	0.0029

Table 1: Koeficijenti diferencijskih jednadžbi koje opisuju vremenski diskretne sustave za detekciju tonova.

2.3 Metoda za detekciju znamenaka

Naša metoda za detekciju znamenaka će se sastojati od 7 sustava opisanih diferencijskim jednadžbama. Svaki od 7 sustava detektira nalazi li se jedna specifična frekvencijska komponenta u ulaznom signalu (pobudi). To ćemo raditi pomoću sličnog principa kao što smo objasnili u prošlom primjeru. Svaki od 7 sustava će propuštati samo jednu frekvenciju (ton) od dogovorenih, a sve ostale će gušiti. Ako u određenom vremenskom intervalu izlaz iz jednog od sustava bude amplitude u rasponu od $[-1, 1]$, tada znamo da se frekvencija koju on propušta koristila u generiranju signala, a ukoliko amplituda bude vrlo mala (gotovo zanemariva), tada znamo da se ta frekvencija nije koristila u tom vremenskom intervalu. Prisjetite se da su u svakom vremenskom intervalu samo dvije frekvencije "aktivne", a sve ostale "neaktivne".

Sustavi koje ćemo koristiti u našoj metodi su četvrtog reda, a koeficijenti diferencijskih jednadžbi koje ih opisuju su dani u tablici 1. Frekvencija pored koje su dani koeficijenti sustava naznačuje da sustav propušta (detektira) tu frekvenciju, a ostale guši. Desne polovice spektara svih sustava prikazane su na slici 3. Amplitudni spektri realnih sustava su simetrični oko $\Omega = 0$, ali je lijeva polovica izostavljena zbog preglednosti.

Pokažimo kako implementirati našu metodu uz pomoć Simulinka. Razmotrimo prvo kako bi izgledao blokovski dijagram vremenski diskretnog

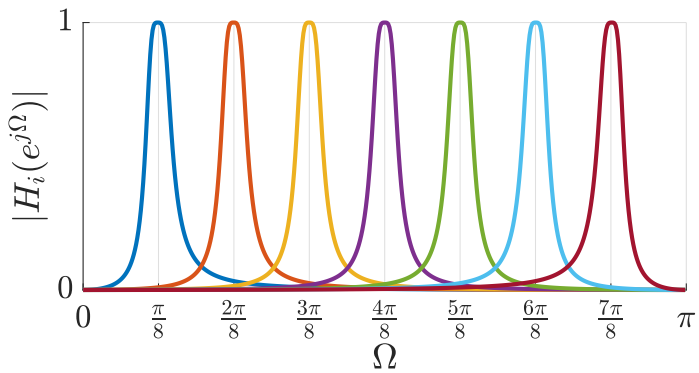

Figure 3: Amplitudno-frekvencijske karakteristike svih 7 diskretnih sustava.

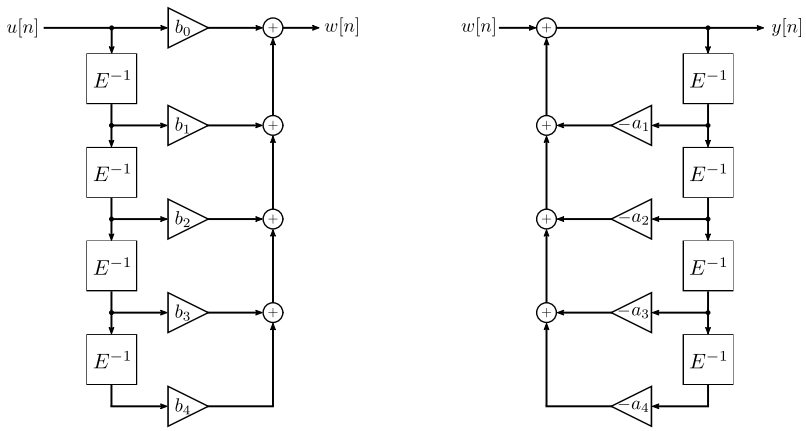

Figure 4: Sastavni elementi vremenski diskretnog sustava četvrtog reda.

kauzalnog sustava četvrtog reda opisanog diferencijskom jednadžbom:

$$a_0y[n] + a_1y[n-1] + a_2[n-2] + a_3[n-3] + a_4[n-4] = \\ b_0u[n] + b_1u[n-1] + b_2u[n-2] + b_3u[n-3] + b_4u[n-4].$$

Po konvenciji, $a_0 = 1$. Uvedemo li novi signal $w[n]$, polaznu jednadžbu možemo rastaviti na dvije jednostavnije

$$y[n] + a_1y[n-1] + a_2y[n-2] + a_3[n-3] + a_4[n-4] = w[n]$$

i

$$w[n] = b_0u[n] + b_1u[n-1] + b_2u[n-2] + b_3u[n-3] + b_4u[n-4].$$

Simulacijski blokovski dijagrami za dvije jednostavnije jednadžbe prikazani su na slici 4. Kako bi dobili efikasniju strukturu s manjim brojem elemenata za kašnjenje, dva podsustava se spajaju obrnutim redoslijedom. Takav simulacijski blokovski dijagram se naziva direktna II realizacija, koju ucrtavamo u Simulink [3].

[3] naredba *filter* je također direktna II realizacija

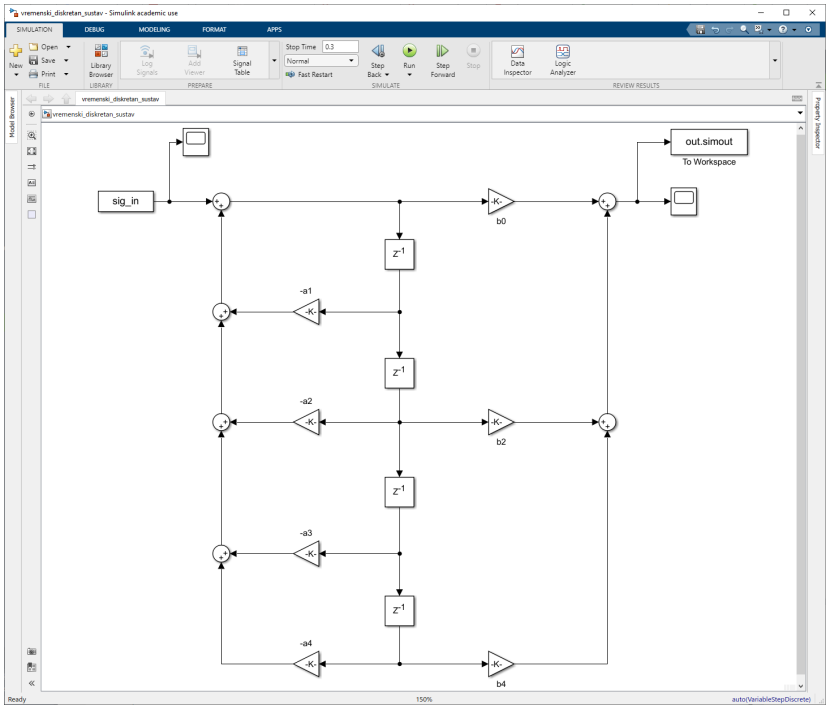

Figure 5: Vremenski diskretan sustav u Simulinku.

Na slici 5 prikazana je direktna II realizacija vremenski diskretnog sustava kojeg ćemo koristiti za određivanje odziva na dvotonski multifrekvencijski ulazni signal.

Model se sastoji od sljedećih blokova koji se mogu pronaći u *Library Browseru*:

- Delay - u kategoriji *Simulink/Discrete* (*delay length* treba biti 1);
- Gain - u kategoriji *Simulink/Math Operations*;
- Sum - u kategoriji *Simulink/Math Operations*;
- From Workspace - u kategoriji *Simulink/Sources*;
- Scope - u kategoriji *Simulink/Sinks*;
- To Workspace - u kategoriji *Simulink/Sinks*.

Takav Simulink model možemo iskoristiti za sve sustave definirane u tablici 1. Najprije moramo postaviti u *To Workspace* bloku *Save format* na *Array* (dvostrukim klikom miša na blok). U *From Workspace* bloku postavite *Data* polje na *sig_in*. Tako ćemo u Workspaceu nazvati varijablu u kojoj se nalazi naša pobuda.

```
1  %% Učitavanje signala
2  jmbag = '0123456789';  % vaš JMBAG
3  load([jmbag, '_dtmf_signal.mat']);  % učitavanje ulaznog signala
4                                      % sig_in u Workspace
5
6  N = length(sig_in);  % broj uzoraka signala
7  n_sim = (0:N-1);  % diskretni trenutci
```

Listing 4: Učitavanje preuzetog signala.

Zadatak 4. Iz zip datoteke *dtmf_signals.zip* u mapi *5. laboratorijska vježba* u repozitoriju preuzmite signal pod vašim JMBAG-om (*JMBAG_dtmf_signal.mat*) i spremite ga u MATLAB radni direktorij. Neka on bude pobuda sustava. Učitajte vaš signal pomoću kodnog isječka iz Listing 4. Naziv varijable u kojoj će biti spremljena pobuda sustava je *sig_in* te će biti vidljiva u *Workspaceu* kada se izvede *load* naredba (linija 3 iz Listinga 4). Broj uzoraka ulaznog signala odredite pomoću naredbe *length*.

Sada definirajmo dodatne varijable u MATLAB-u kao u Listingu 5. *From*

```
%% Definiranje varijabla
Fs = 8000;  % frekvencija očitavanja
t_sim = n_sim/Fs;  % vremenski trenutci očitavanja

% koeficijenti sustava
B = repmat([0.0029, 0, -0.0058, 0, 0.0029], 7, 1);
A = [1, -3.5548, 5.0054, -3.2832, 0.8533; ...
     1, -2.7207, 3.6949, -2.5129, 0.8533; ...
     1, -1.4724, 2.3844, -1.3600, 0.8533; ...
     1, 0, 1.8416, 0, 0.8533; ...
     1, 1.4724, 2.3844, 1.3600, 0.8533; ...
     1, 2.7207, 3.6949, 2.5129, 0.8533; ...
     1, 3.5548, 5.0054, 3.2832, 0.8533];

% pobuda
sig_in = [t_sim', sig_in]; % u prvom stupcu se nalaze vremenski
                           % trenutci očitavanja, a u drugom
                           % vrijednosti signala
```

Listing 5: Definiranje varijabla za simulaciju.

Workspace blok traži da ulazni signal (*sig_in*) u prvom stupcu sadrži vremenske trenutke simulacije, a u drugom vrijednosti signala u tim trenutcima.

```
1  %% Pokretanje Simulink simulacije iz MATLAB-a
2  simOut = repmat(Simulink.SimulationOutput, 7, 1); % alocirajmo
3              % prostor u koji ćemo spremati rezultate simulacije
4  figure;  % otvorimo prozor u koji ćemo crtati odzive
5  for i = 1 : 7
6      B_sim = B(i,:);  % odvajamo jedan redak iz B matrice
7                       % koeficijenti ulazne strane
8      A_sim = A(i,:);  % odvajamo jedan redak iz A matrice
9                       % koeficijenti izlazne strane
10     % pokrećemo simulaciju sustava
11     simOut(i) = sim('vremenski_diskretan_sustav');
12     % crtamo rezultate simulacije
13     subplot(7,1,i); plot(simOut(i).tout, simOut(i).simout);
14     ylim([-1,1]); title(['sustav ', num2str(i)]);
15 end
```

Listing 6: Kodni isječak za pokretanje Simulink simulacije iz MATLAB skripte.

U Listingu 5 pokazano je kako definirati ulazni signal na taj način. U Simulink modelu potrebno je odrediti trajanje simulacije. U našem slučaju će to biti kvocijent između broja uzoraka signala N i frekvencije očitavanja F_s. Nadalje, potrebno je u blokovima *From Workspace, Scope, Delay i To Workspace* postaviti *Sample time* na $1/F_s$.

Pomoću naredbe *sim* pokrenut ćemo simulacije u Simulinku iz skripte. Listing 6 prikazuje kodni isječak za pokretanje simulacije iz MATLAB skripte. Simulaciju ćemo pokrenuti 7 puta – pobuđujemo svaki od diskretnih vremenskih sustava istim ulaznim signalom. U 6. i 8. liniji koda u Listingu 6 *B_sim* i *A_sim* određuju koeficijente sustava za pojedinu iteraciju. Prije pokretanja simulacije moramo u modelu u Simulinku postaviti još jednu stvar. U *Gain* blokovima postavljamo *Gain* polja na *A_sim* odnosno *B_sim* uz odgovarajuće indekse (dvostrukim klikom miša na blokove). Npr. za b_0 *Gain* blok postavljamo *Gain* na *B_sim(1)* vidi sliku 6.

Primjere odziva sustava na jedan DTMF signal možete vidjeti na slici 7. Gledajući odzive možemo zaključiti da je sustav detektirao u prvom vremenskom odjsečku tonove frekvencija 1000 Hz i 3000 Hz, u drugom tonove frekvencija 2000 Hz i 3000 Hz i u trećem tonove frekvencija 500 Hz i 3000 Hz. Koje su znamenke bile kodirane takvim ulaznim signalom?

Zadatak 5. Odredite izlaze iz sustava na pobudu koju ste preuzeli iz repozitorija i detektirajte koje su redom 3 znamenke bile kodirane takvim signalom.

Varijable iz radnog prostora (*Workspace*) po završetku vježbe pohranite u

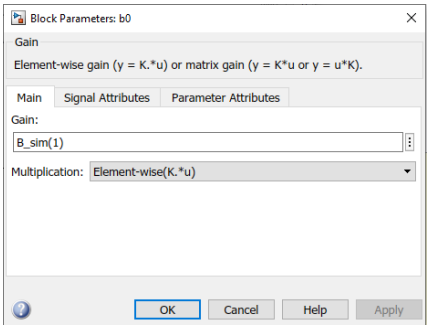

Figure 6: Primjer postavljanja *Gain* vrijednosti u bloku b_0.

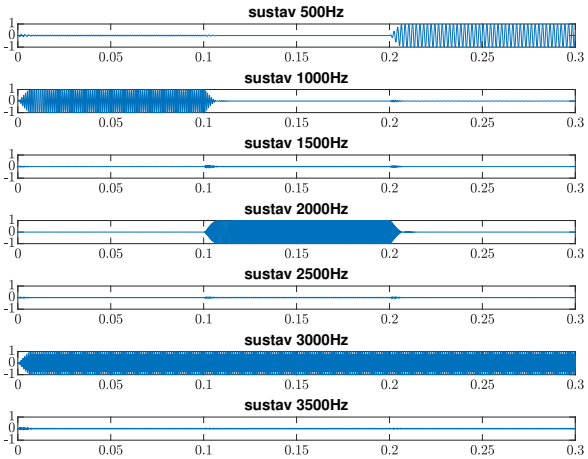

Figure 7: Odzivi na jedan primjer DTMF signala.

datoteku "JMBAG.mat", gdje JMBAG treba zamijeniti vašim matičnim brojem.

Ne zaboravite predati vaše rezultate koje ste dobili u MATLAB-u na Moodle, posljednji zadatak!

U predanom radnom prostoru moraju se nalaziti varijable:

- jmbag – character niz s 10 znamenaka vašeg JMBAG-a,
- t_sim – $1 \times N$ vektor s vremenskim trenutcima očitavanja,
- B – 7×5 matrica s koeficijentima ulazne strane svih diskretnih sustava,
- A – 7×5 matrica s koeficijentima izlazne strane svih diskretnih sustava,
- sig_in – $N \times 2$ matrica s vremenskim trenutcima očitavanja i vrijednostima ulaznog signala (vidi Listing 5),
- decoded_numbers – 1×3 red vektor s detektiranim znamenkama (vidi Listing 7).

```
%% Spremi dekodirane znamenke
% ako ste na primjer dekodirali redom znamenke 0, 1, 3
% spremanje napravite na sljedeći način
decoded_numbers = [0, 1, 3];

% slobodno pobrišite viškove
clearvars -except jmbag t_sim B A sig_in decoded_numbers

% konačno spremite workspace na sljedeći način
save 0123456789.mat  % 0123456789 označava vaš JMBAG
```

Listing 7: Spremanje dekodiranih brojeva.