Odziv LTI sustava
Model s varijablama stanja

Šesta laboratorijska vježba iz Signala i sustava

Grupa autora

Sadržaj

1 Uvod **2**

2 Ulazno-izlazni model LTI sustava **2**
2.1 Priprema 3
2.2 Snimanje 5

3 Odziv LTI sustava **8**

4 Model sustava s varijablama stanja **8**
4.1 Snimanje trajektorije 9

5 Predikcija trajektorije stanja **11**
5.1 Zadaci 11
5.2 Epilog 13

1 Uvod

Laboratorijske vježbe iz Signala i sustava će vas približiti problematici obrade signala te analize i simulacije sustava. Sve vježbe se izvode na računalu u programskom sustavu MATLAB[1]. Osim što posjeduje mogućnost izvođenja raznih matematičkih operacija, numeričkih i simboličkih, MATLAB[2] sadrži i modul Simulink[3] koji je vizualni alat za brzo i jednostavno simuliranje sustava. S MATLAB-om i Simulinkom ste se upoznali na uvodnoj laboratorijskoj vježbi.

FER-ova licenca vam omogućuje lokalnu instalaciju ovog programskog paketa, ali i *online* korištenje. Napomenimo da osim komercijalnog programskog paketa MATLAB postoji i javno dostupni GNU Octave[4] koji je gotovo kompatibilan (bez Simulinka), a vrlo je sličan i SciPy[5] paket za Python[6].

Dio rezultata vježbe potrebno je predati preko FER-ovog Moodle[7] sustava, a datoteku s rezultatima je potrebno postaviti na mrežni disk do zadanog roka. Dozvoljeno je konzultirati se s kolegama, ali uz samostalni rad. Ovisno o zadatku, unose se numerički rezultati, slike ili programski kod. Svrha laboratorijskih vježbi jest učenje, odnosno bolje razumijevanje koncepata signala i sustava, kao i njihova primjena. Stoga svaki zadatak možete ponoviti neograničen broj puta, dok ne zaključite da ste dobili točan rezultat. U tome vam mogu pomoći i naši asistenti ili demonstratori.

Za prolaz predmeta morate pristupiti svim laboratorijskim vježbama i u svakoj ostvariti barem polovicu točnih rezultata. Uopće ne sumnjamo da ćete baš Vi imati 100% točnih!

2 Ulazno-izlazni model LTI sustava

Prvi dio šeste laboratorijske vježbe bavi se vremenski diskretnim sustavima koje opisujemo pomoću diferencijskih jednadžbi sa stalnim koeficijentima. Koristit ćemo model s ulazno-izlaznim varijablama. Naučit ćemo kako u MATLAB-u izračunati impulsni odziv sustava, odziv na jediničnu stepenicu te nacrtati frekvencijsku karakteristiku. Prikazat ćemo polove i nule sustava, provjeriti stabilnost i po potrebi korigirati model. Posebnost ovog dijela laboratorijske vježbe jest što će sustav biti aproksimativni model stvarnog audio sustava: vašeg zvučnika, prostorije u kojoj se nalazite i mikrofona na vašem računalu.

[1] https://www.fer.unizg.hr/matlab
[2] https://www.mathworks.com/products.html?s_tid=gn_ps
[3] https://www.mathworks.com/products/simulink.html
[4] https://octave.org/
[5] https://scipy.org/
[6] https://www.python.org/
[7] https://moodle.fer.hr/

Vremenski diskretan, linearan, vremenski stalan i kauzalan sustav možemo opisati linearnom diferencijskom jednadžbom s konstantnim koeficijentima:

$$y[n] + a_1 y[n-1] + ... + a_N y[n-N] = b_0 u[n] + b_1 u[n-1] + ... + b_M u[n-M].$$

Kako se na lijevoj strani jednadžbe diferencija nalaze izlazni signal i njegovi pomaci, a na desnoj ulazni signal i njegovi pomaci, ovakav model naziva se još i ulazno-izlazni model. Jednadžbi diferencija pridružena je i prijenosna funkcija:

$$H(z) = \frac{b_0 + b_1 z^{-1} + ... + b_M z^{-M}}{1 + a_1 z^{-1} + ... + a_N z^{-N}}$$

Ponašanje takvog sustava u potpunosti je karakterizirano njegovim nulama i polovima. Nule sustava su korijeni jednadžbe:

$$b_0 u[n] + b_1 u[n-1] + ... + b_M u[n-M] = 0,$$

odnosno radi se o nulama prijenosne funkcije $H(z)$. Slično, polovi sustava su korijeni karakteristične jednadžbe:

$$y[n] + a_1 y[n-1] + ... + a_N y[n-N] = 0,$$

odnosno radi se o polovima prijenosne funkcije $H(z)$. U nastavku ćemo koristiti primjer sustava drugog reda ($N = M = 2$) koji će biti aproksimativni model stvarnog audio sustava.

2.1 Priprema

Postupak nalaženja koeficijenata a_1, a_2, b_0, b_1 i b_2 naziva se identifikacija sustava. U ovom slučaju radi se o parametarskoj identifikaciji: traže se koeficijenti (parametri modela) koji najbolje opisuju neki stvarni sustav. Postupci identifikacije sustava detaljno se izučavaju na diplomskom studiju. Stoga ćemo ovdje napraviti jednostavan ilustrativni primjer i dati kratke upute koje će vam omogućiti da to izvedete sami!

Ilustrativni primjer je regresija pravca: pronalaženje koeficijenata pravca koji najbolje odgovaraju nekom skupu točaka. Jednadžba pravca nam je unaprijed poznata, a sastoji se od dva koeficijenta: a i b. Kada bi postojale samo dvije točke (x_1, y_1) i (x_2, y_2), pravac bi bio jednoznačno zadan. Parametre bismo izračunali rješavajući sustav s dvije jednadžbe i dvije nepoznanice. Međutim, mi imamo oblak točaka čiji je broj znatno veći od dva: $X = [x_1, x_2, ..., x_N]^T$, $Y = [y_1, y_2, ..., y_N]^T$ i $N >> 2$. Sustav je prezadan, pa jedino što nam preostaje jest pronaći rješenje uz najmanje kvadratno odstupanje izlazne varijable.

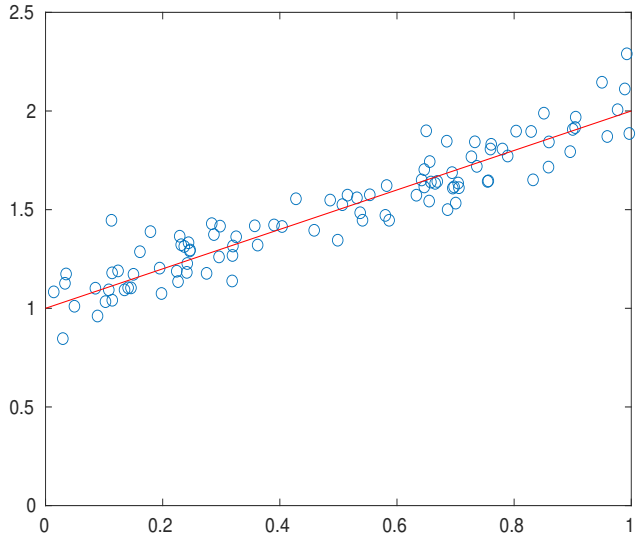

Iz modela:

$$y = ax + b$$

pišemo matričnu jednadžbu:

$$Y = \begin{bmatrix} X & \mathbf{1} \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix},$$

gdje su X i Y gore navedeni vektori podataka (na slici prikazani oblakom točaka), a $\mathbf{1}$ je vektor jedinica. Rješenje s najmanjom kvadratnom pogreškom dobije se rješavanjem sustava:

$$\begin{bmatrix} X & \mathbf{1} \end{bmatrix}^T Y = \begin{bmatrix} X & \mathbf{1} \end{bmatrix}^T \begin{bmatrix} X & \mathbf{1} \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix}.$$

Uvedimo oznake $Phi = \begin{bmatrix} X & \mathbf{1} \end{bmatrix}$ i $theta = \begin{bmatrix} a \\ b \end{bmatrix}$. U MATLAB-u rješenje gornjeg izraza daje tzv. lijevo dijeljenje:

$$theta = Y \backslash Phi,$$

a cijeli postupak se naziva linearna regresija.

Nešto vrlo slično napravit ćemo i za naš sustav s ulazno-izlaznim modelom drugog reda. Reproducirati ćemo neki nama poznati audio signal U te ćemo istovremeno snimiti odziv Y. Kako se u našoj jednadžbi diferencija javljaju Y_n, U_n, ali i njihovi pomaci (zakašnjele verzije) Y_{n-1}, Y_{n-2}, U_{n-1}, U_{n-2}, tako će i matrica Phi morati odražavati tu činjenicu! Naravno, $theta$ će sadržavati tražene parametre a_1, a_2, b_0, b_1 i b_2.

```
%% Audio recorder initialization
Fs = 44100; % Sampling rate 44.1 kHz
Nb = 16;    % Number of bits 16
Nc = 1;     % Number of channels 1 (mono)
ID = -1;    % Audio device identifier (default)
T  = 4;     % Recording duration 4 sec

info = audiodevinfo % Returns information about the input
                    % and output audio devices on the system
info.input(1) % Display the information about
              % the first input device
% optional
% ID = 0; % uncomment to select the input audio device
          % specified by the device identifier (ID) 0

% Create an audio recording object
recObj = audiorecorder(Fs, Nb, Nc, ID);
```

Listing 1: Inicijalizacija audio recordera

```
%% Audio player initialization
U = randn(T*Fs, 1); % Random noise
playObj = audioplayer(U, Fs);
```

Listing 2: Inicijalizacija audio playera

2.2 Snimanje

Najprije morate inicijalizirati audio recorder (Listing 1). Ako želite odabrati određeni ulazni audio uređaj najprije koristite naredbu *audiodevinfo* koja vraća informacije o audio uređajima spojenim na sustav. Zatim provjerite koji ID je dodijeljen vašem željenom uređaju te u varijablu ID zapišite ID tog uređaja.

Zatim morate inicijalizirati i audio player (Listing 2). Ovdje smo pripremili i slučajni šum, kojeg ćemo reproducirati na našem sustavu. Postavite glasnoću na računalu na otprilike 2/3. Provjerite da reprodukcija i snimanje radi.

Naš sljedeći korak je istovremena reprodukcija i snimanje zvuka. Pobrinite se za tišinu u prostoriji. Pokrenite programski odsječak (Listing 3). Naravno, prikazat ćete i preslušati snimljeno, kako biste se uvjerili da je sve u redu. Magnituda snimljenog signala trebala bi biti veća od 0.2 a manja od 1, kada bi signal ušao u zasićenje. Provjerite postavke mikrofona i zvučnika. Ponovite postupak po potrebi.

Zapišimo jednadžbu diferencija drugog reda tako da samo $y[n]$ ostavimo

```
%% Simultaneously execute the following two commands (Ctrl+ENTER):
recObj.record(T);
play(playObj)

%% Recorded data
Y = getaudiodata(recObj); % Extract the audio data

%% Check the recording
% Extract the central parts
U = wkeep(U, 2*Fs);
Y = wkeep(Y, 2*Fs);

% Plot the result
figure, plot(Y), grid

% Repeat the measurements if needed
```

Listing 3: Istovremeno snimanje i reprodukcija, provjera rezultata

na lijevoj strani:

$$y[n] = -a_1 y[n-1] - a_2 y[n-2] + b_0 u[n] + b_1 u[n-1] + b_2 u[n-2].$$

Mi imamo vektore podataka U_n i Y_n, a dodavanjem nula na početku i izrezivanjem viškova na kraju dobit ćemo i vektore Y_{n-1}, Y_{n-2}, U_{n-1}, U_{n-2}. Konačno, naš prezadani sustav jednadžbi glasi:

$$Y_n = \begin{bmatrix} Y_{n-1} & Y_{n-2} & U_n & U_{n-1} & U_{n-2} \end{bmatrix} \begin{bmatrix} -a_1 \\ -a_2 \\ b_0 \\ b_1 \\ b_2 \end{bmatrix}.$$

Uz oznake $Phi = \begin{bmatrix} Y_{n-1} & Y_{n-2} & U_n & U_{n-1} & U_{n-2} \end{bmatrix}$ i $theta = \begin{bmatrix} -a_1 \\ -a_2 \\ b_0 \\ b_1 \\ b_2 \end{bmatrix}$, rješenje je također:

$$theta = Y_n \setminus Phi.$$

Listing 4 prikazuje kako ćemo identificirati vaš audio sustav, koji se sastoji od pojačala, zvučnika, akustike prostorije te mikrofona.

```
% Phi = [Y(n-1) Y(n-2) U(n) U(n-1) U(n-2)]
%     and
% Theta = [-a1 -a2 b0 b1 b2] '
Phi = [[0; Y(1:end-1)], [0; 0; Y(1:end-2)], ...
U, [0; U(1:end-1)], [0; 0; U(1:end-2)]];

% Solve the overdetermined system Phi * Theta = Y :
Theta = Y \ Phi;
% Such a solution ensures the least square error in Y

a = [1 -Theta(1:2)]; % Left hand side of the difference equation
b = Theta(3:end); % Right hand side of the difference equation

%% Results
figure
zplane(b, a) % Pole-zero plot

%% Mirroring poles to ensure the stability of the model
aroots = roots(a);
% Check if there are poles outside the unit circle...
ind = abs(aroots) > 1;
% ..and mirror them to the reciprocal positions:
aroots(ind) = aroots(ind) ./ abs(aroots(ind)).^2;
a = poly(aroots); % Back to the polynomial coefficients

figure
zplane(b, a) % Pole-zero plot after (eventual) stabilization
```

Listing 4: Identifikacija sustava

Parametri modela dobiveni regresijom ne jamče stabilnost sustava. Postoji mogućnost da su neki polovi izvan jedinične kružnice. U tom slučaju (tj. ako je neki $|p_k| > 1$), pronaći ćemo sustav identične frekvencijske karakteristike zrcaljenjem takvih polova:

$$p_k = \frac{p_k}{|p_k|^2}.$$

Nacrtajte frekvencijsku karakteristiku sustava korištenjem funkcije *freqz*. Po potrebi pročitajte dokumentaciju navedene funkcije.

Jeste li zadovoljni svojstvima vašeg audio sustava, ili je možda vrijeme za kupovinu novog :-) ?

PS

Prije nego krenete u kupovinu... možda je ipak model drugog reda nedovoljno dobar da bi vjerno opisao vaš super-izvrsni-sustav :-).

3 Odziv LTI sustava

Za dobiveni sustav

$$H(z) = \frac{b_0 + b_1 z^{-1} + b_2 z^{-2}}{1 + a_1 z^{-1} + a_2 z^{-2}}$$

izračunajte i nacrtajte:

a) impulsni odziv,

b) odziv mirnog sustava na jediničnu stepenicu,

c) odziv na pobudu $u[n] = \cos(2\pi \cdot 440\, nT_s)\mu[n]$ uz početna stanja 1 i 1 (direktna II realizacija).

Za izračun odziva koristite funkciju *filter*. Neka je pobudni signal u svim primjerima dugačak 100 uzoraka. Po potrebi pročitajte dokumentaciju funkcije *filter*.

4 Model sustava s varijablama stanja

U drugom dijelu ove laboratorijske vježbe koristiti ćemo model s varijablama stanja:

$$X[n+1] = A\,X[n] + B\,U[n],$$

$$Y[n] = C\,X[n] + D\,U[n],$$

gdje je A matrica sustava, B ulazna matrica, C izlazna matrica, dok matrica D direktno povezuje ulaze i izlaze. Naučili ste prelaziti iz modela s ulazno-izlaznim varijablama u model s varijablama stanja i to na više načina, pa bismo mogli koristiti i naš prethodno dobiveni model audio sustava. Ipak, u

ovom dijelu ćemo radije zadati sasvim novi model s varijablama stanja i to iz fotografije vašeg lica.

U MATLAB okolinu ćete učitati jednu fotografiju vašeg lica. Neka to bude portret, slično kao za osobnu iskaznicu. Uvećat ćete fotografiju preko cijelog zaslona i po uputama u smjeru kazaljke na satu označiti rubove lica u 20 točaka jednolikim ritmom.

Zatim ćemo koristiti jednadžbu gibanja kako bismo opisali model s varijablama stanja.

Na kraju ćemo dodatnim izračunima u prostoru stanja pokušati predvidjeti kretnje vaše ruke iz prethodnih očitanja. U ovom kolegiju ste se već sretali s pojmom kauzalnosti, odnosno kauzalnih sustava. Pokušaj da se iz prethodnih očitanja predvidi neka buduća vrijednost jest aproksimacija nekog zamišljenog nekauzalnog sustava.

4.1 Snimanje trajektorije

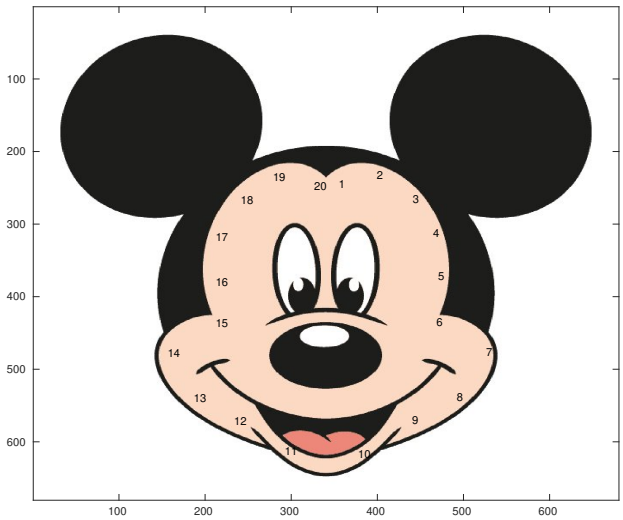

Listing 5 je programski kod kojim ćete učitati fotografiju SVOG lica. Uvećajte sliku preko cijelog ekrana. Brojite naglas radi ujednačenog ritma i kliknite N puta prolazeći od vrha lica u smjeru kazaljke na satu po rubovima lica. Brojanje će pomoći da se klikovi događaju otprilike svake sekunde. Računajte da imate oko N/4 klikova po svakom kvadrantu.

```
im = imread('ngc6543a.jpg'); % Read your face photo here
figure
image(im)
hold on

N = 20;

% Resize the photo to fit the full screen.
% Count out loud and click N times,
% starting from the top of the face.
% Proceed in a clockwise direction,
% marking the edges of the face.
% Counting will ensure that the intervals between the clicks are
% approximately 1 second.
% Note that N/4 clicks should be made in each quadrant.

[X, Y] = ginput(N); % Edge of the face coordinates

plot(X, Y);
% If you succeeded, the curve frames your face.
% If not - repeat the procedure!
```

Listing 5: Snimanje trajektorije

5 Predikcija trajektorije stanja

U ovom dijelu pokušati ćemo realizirati kristalnu kuglu koja će predvidjeti pokrete vaše ruke.

Koristiti ćemo jednadžbu gibanja za jednostavnu predikciju:

$$x[n+1] = x[n] + v_x[n] \cdot deltaT,$$

gdje su x i v_x pozicija i brzina u smjeru osi x. Pretpostavit ćemo da je brzina konstantna:

$$v_x[n+1] = v_x[n].$$

Ponovimo isto i za y os:

$$y[n+1] = y[n] + v_y[n] \cdot deltaT,$$

$$v_y[n+1] = v_y[n].$$

Četiri jednadžbe stanja koje smo upravo zapisali možemo predstaviti i u matričnom obliku $X_{st}[n+1] = A \cdot X_{st}[n]$. Izlazna jednadžba $Out[n] = C \cdot X_{st}[n]$ iz vektora stanja izdvaja koordinate x i y.

$$X_{st} = \begin{bmatrix} x \\ v_x \\ y \\ v_y \end{bmatrix}, \; A = \begin{bmatrix} 1 & \Delta_t & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & \Delta_t \\ 0 & 0 & 0 & 1 \end{bmatrix} \; B = 0, \quad C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \; D = 0$$

Cijeli postupak opisuje Listing 6, uključujući i nekoliko matričnih operacija u prostoru stanja (linije 32-38), koje služe za inteligentnu korekciju predikcije na temelju pogreške i izlaze iz gradiva ovog predmeta [8].

Provedite postupak na vašim podacima. U našim eksperimentima predviđanje je bilo prilično uspješno, pa bismo rado iskoristili takav sustav npr. za predviđanje vrijednosti dionica, ili možda vjerojatnosti prepisivanja na ispitima :-).

5.1 Zadaci

Nacrtajte na istoj slici ulazne signale X, Y i predviđanja $Out(1,:)'$, $Out(2,:)'$.

a) Izračunajte srednju snagu pogreške predviđanja za X i Y signal (*xErr* i *yErr*).

b) Izračunajte maksimalno apsolutno odstupanje (pogrešku) predviđanja X i Y signala (*xErrMax* i *yErrMax*).

Vektor $Out(1,:)'$ daje predviđanje ulaznog signala X, dok vektor $Out(2,:)'$ daje predviđanje ulaznog signala Y.

[8] Za one koje žele znati više: Kalmanov filtar

```
% Movement equation in the state-space representation:
%  x[n+1]  = x[n] + vx[n] * deltaT;
% vx[n+1] =           vx[n];
%  y[n+1]  = y[n] + vy[n] * deltaT;
% vy[n+1] =           vy[n];
%
% 4 equations in matrix form:
% Xst[n+1] = A * Xst[n];
% where state vector is: Xst = [x vx y vy] ' ;
% and the system matrix A is:
A = eye(4);
A(1,2) = 0.01; % deltaT
A(3,4) = 0.01;
% B=0 % Input matrix is zero
% Output matrix: only X and Y coordinates are observable:
C = [1 0 0 0; 0 0 1 0];
% D=0 % Input/output matrix is zero

% Initialization
Out = zeros(2, N); % Allocate space for the result
Xst = [X(1) 10 Y(1) 10]'; % Initial state vector
Out(:,1) = [X(1) Y(1)]';
P = eye(4);

for n=2:N
    % State equation
    Xst = A * Xst; % A - equation of movement in matrix form

   % Output equation
    Out(:,n) = C*Xst;

    % A little bit of magic
    P = A*P*A' + eye(4);

    % Correction using the real data
    K = P*C' / (C*P*C'); % gain
    Xst = Xst + K*([X(n); Y(n)] - C * Xst);
    % Correction = gain * error
    P = (eye(4) - K*C)*P;
end

%% Plot the result
plot(Out(1,:)', Out(2,:)', 'y')
hold off
```

Listing 6: Predviđanje trajektorije

5.2 Epilog

Laboratorijske vježbe iz Signala i sustava povezale su gradivo sa stvarnim primjerima. Dio primjera je izveden iz koncepata koji se uče na nekim smjerovima na diplomskom studiju, ali na način koji i preddiplomski studenti mogu reproducirati i načelno razumjeti. Nadamo se da smo vam uspjeli približiti teoriju signala i sustava te motivirati vas kako biste je i sami primijenili u izazovnim inženjerskim zadacima!

Pobrišite viškove naredbom

```
clearvars -except a b h s yc X Y Out xErr yErr xErrMax yErrMax
```

Sve preostale varijable iz radnog prostora pohranite u datoteku "JMBAG.mat":

save 0123456789.*mat*

gdje 0123456789 treba zamijeniti vašim matičnim brojem.

Ne zaboravite predati vaše rezultate koje ste dobili u MATLAB/Octave-u u sustav Moodle, posljednji zadatak!

U predanom radnom prostoru moraju se nalaziti varijable:

- a i b u kojima su spremljeni koeficijenti stabilnog sustava 2. reda koji su dobiveni sustavom zvučnik-mikrofon ($a = [1, a_1, a_2]$, $b = [b_0, b_1, b_2]$),
- h (vektor od 100 uzoraka) u kojem se nalazi impulsni odziv sustava (Zadatak 3.a)),
- s (vektor od 100 uzoraka) u kojem se nalazi odziv mirnog sustava na jediničnu stepenicu (Zadatak 3.b)),
- yc (vektor od 100 uzoraka) u kojem se nalazi odziv sustava na pobudu $u[n] = \cos(2\pi \cdot 440\, nT_s)\mu[n]$ pri čemu su početna stanja 1 i 1 (zadatak 3.c)),
- X i Y (svaki je vektor od 20 uzoraka) u kojem su spremljene koordinate ruba lica (Zadatak 5.1)),
- Out (matrica dimenzija 2×20) u kojem se nalaze predviđanje ruba lica (Zadatak 5.1))
- $xErr$ i $yErr$ u kojima je spremljena snaga pogreške predviđanja X i Y signala (Zadatak 5.1.a)),
- $xErrMax$ i $yErrMax$ u kojima se nalazi maksimalno apsolutno odstupanje predviđanja X i Y signala (Zadatak 5.1.b)).